



Voxprint AI Audiobook Builder

Benutzerhandbuch

Version 0.1.0 (Beta) · Handbuch vom 3. Oktober 2026

Apache-2.0 · © 2026 Aleksandr Mitroshenkov

Inhalt


1	Was Voxprint macht	3
1.1	Was Sie brauchen	4
1.2	So funktioniert es in fünf Schritten	4
2	Installation.....	5
2.1	Das Installationsprogramm	5
2.2	Erster Start.....	5
2.3	Wo was gespeichert wird.....	5
3	Schnellstart.....	6
4	Das Studio (Startbildschirm).....	7
5	Ein Buch vertonen	9
5.1	Schritt 1 – das Buch	9
5.2	Schritt 2 – die Stimme	10
5.3	Schritt 3 – Text vorbereiten.....	10
5.4	Schritt 4 – Ausgabeformat und Qualität.....	11
5.5	Starten, pausieren, anhalten.....	12
5.6	Geschwindigkeit	13
6	Eigene Stimme trainieren	14
6.1	Die Stimme aufnehmen	14
6.2	Das Trainingsfenster	14
6.3	Trainingsstufen	16
6.4	Kein Text? (nur Audio)	17
6.5	Schnelle Vorschau und Vergleich zweier Varianten	18
6.6	Die Einverständniskarte.....	19
6.7	Das Universalmodell (optional).....	20
7	Meine Stimmen	21
7.1	Online-Stimmen und das Stimmen-Repository	23
7.2	Eine Stimme importieren.....	23
7.3	Lizenzen und die Stimme, die Voxprint anbietet	24
8	Einstellungen	25
8.1	Maximale Qualität (automatisch)	26
9	Glossar	28
10	Fehlerbehebung und häufige Fragen	30
11	Lizenzen und Verantwortung.....	32

1 Was Voxprint macht

Voxprint AI Audiobook Builder ([Stimme trainieren](#), [Bücher vertonen](#)) ist eine Windows-11-Anwendung, die zwei Dinge vollständig auf Ihrem eigenen Computer erledigt:

1. **Sie bringt einer Computerstimme bei, wie eine bestimmte Person zu klingen.** Sie geben eine Aufnahme einer Stimme (Ihrer eigenen oder der einer Person, die zugestimmt hat) – am besten 5 bis 15 Minuten – und, falls vorhanden, den gelesenen Text. Voxprint richtet Text und Ton aufeinander aus, schneidet die Aufnahme in saubere Stücke und trainiert ein kleines Stimm-Add-on (einen *Adapter*, technisch LoRA) für das Sprachmodell **Qwen3-TTS**.
2. **Sie liest ganze Bücher mit dieser Stimme vor.** Sie wählen ein Buch (TXT, FB2 oder EPUB) und eine Stimme aus Ihrer Bibliothek und erhalten ein fertiges Hörbuch mit Kapiteln – eine Opus-Datei, eine MP3 pro Kapitel und so weiter.

Es gibt keine Kommandozeile, keinen Browser und kein Benutzerkonto. Aufnahmen, Texte, Stimmen und Ergebnisse bleiben auf dem Computer. Das Programm geht nur ins Internet, um Modelle herunterzuladen, nach Updates zu suchen und – wenn Sie es verlangen – Stimmen aus dem Stimmen-Repository zu laden.



Das Studio – der erste Bildschirm von Voxprint (dunkles Design, deutsche Oberfläche).

Beta-Software. Version 0.1.0 wurde auf einem Rechner (Windows mit NVIDIA RTX 4090) und mit im Wesentlichen einem Sprecher von Anfang bis Ende getestet. Rechnen Sie mit Ecken und Kanten; bewahren Sie eine Kopie Ihrer Aufnahmen und Stimmen auf (siehe „ [Modelle und Stimmen](#) “ in Kapitel 8).

1.1 Was Sie brauchen

	Minimum	Empfohlen
Betriebssystem	Windows 11 24H2 (Build 26100), 64 Bit	Windows 11 26H2
Grafikkarte	NVIDIA mit etwa 6 GB Videospeicher (VRAM)	NVIDIA mit 16 GB VRAM oder mehr
Ohne NVIDIA-Karte	Der Datensatz wird trotzdem erstellt; das Training läuft auf dem Prozessor und dauert viele Stunden (das Programm warnt Sie)	–
Speicherplatz	etwa 12 GB (Modelle etwa 7 GB + Programm), plus etwa 4,2 GB für das optionale Universalmodell	eine SSD
Internet	einmalig, um die Modelle herunterzuladen (etwa 7 GB)	–

1.2 So funktioniert es in fünf Schritten

1. Lesen Sie einen bekannten Text laut vor und nehmen Sie ihn auf (5–15 Minuten).
2. Wählen Sie die Aufnahme und die Textdatei – oder nur die Aufnahme, wenn Sie keinen Text haben.
3. Voxprint richtet den Text mit einem neuronalen Aligner an der Aufnahme aus und schneidet sie in saubere Fragmente – den *Datensatz*.
4. Es trainiert auf Ihrer Grafikkarte einen kleinen Stimm-Adapter.
5. Die Stimme erscheint unter [Meine Stimmen](#) . Nun können Sie damit [Ein Buch vertonen](#) .

Verwenden Sie Stimmen verantwortungsvoll. Eine Stimme ist ein personenbezogenes Datum und ein Persönlichkeitsrecht ihres Inhabers. Verwenden Sie eine Stimme nur mit ausdrücklicher Erlaubnis der Person, der sie gehört, und im Rahmen der Lizenz der Stimme. Siehe Kapitel 11.

2 Installation

2.1 Das Installationsprogramm

Starten Sie **Voxprint-Setup.exe** (Inno Setup, Installation für alle Benutzer des Rechners, etwa 1,8 GB, weil die PyTorch-Bibliotheken enthalten sind). Der Assistent ist auf Englisch, Russisch und Deutsch verfügbar. Nach der Seite für den Installationsordner gibt es eine optionale Seite „**Vorhandene Modelle (optional)**“: Wenn Sie bereits heruntergeladene Modelle einer früheren Installation oder aus einer Sicherung haben, wählen Sie diesen Ordner; sonst lassen Sie das Feld leer. Das Installationsprogramm kopiert nichts – es merkt sich nur den Ordner, und beim ersten Start importiert das Programm die Modelle von dort, statt sie herunterzuladen.

Stille Installation für Administratoren: `Voxprint-Setup.exe /VERYSILENT /ModelsDir="D:\old\models"`.

Wenn das Administratorkonto, das das Installationsprogramm ausführt, ein anderes ist als das Konto, mit dem Sie Voxprint benutzen, gehört der Datenordner dem Administrator. Legen Sie den Ordner mit vorhandenen Modellen dann später unter „**Einstellungen**“ fest (Kapitel 8).

2.2 Erster Start

Beim ersten Start bereitet sich Voxprint vor: Die Statuszeile zeigt „**Erster Start: Das Programm wird vorbereitet (Modelle werden heruntergeladen, einmalig)...**“ Es lädt die benötigten Modelle herunter (etwa 7 GB, einmalig). Ist Hugging Face langsam oder nicht erreichbar, wechselt Voxprint automatisch zum ModelScope-Spiegel. Der Download kann unterbrochen werden und läuft an der gleichen Stelle weiter. Modelle, die schon auf dem Computer liegen (zum Beispiel im Hugging-Face-Cache oder bei Alexandria/Pinokio), werden ohne erneuten Download nur lesend weiterverwendet.

Ist alles fertig, zeigt die Statuszeile „**Alles ist bereit. Wählen Sie Audio und Text.**“ Beim ersten Start erscheint ein Datenschutzhinweis; eine kurze Erinnerung („**Verwenden Sie Stimmen verantwortungsvoll: nur mit Erlaubnis des Stimminhabers und unter Achtung seiner Rechte. Aufnahmen und Ergebnisse bleiben auf diesem Computer.**“) bleibt am unteren Rand der Fenster.

2.3 Wo was gespeichert wird

Was	Wo
Programmdaten, Modelle, Protokolle, Stimmenbibliothek	%LOCALAPPDATA%\Voxprint\ (models\, logs\, voices\, state\)
Hörbücher	Documents\Voxprint\Audiobooks (änderbar unter „ Erweitert “ im Vertonungsfenster)
Trainingsergebnisse	neben Ihrer Aufnahme: <Name der Aufnahme>_Voxprint\dataset und output\<Stimmenname>

Den Modellordner und den Daten- und Protokollordner öffnen Sie mit Schaltflächen unter „**Einstellungen**“.


3 Schnellstart

Ich möchte nur ein Buch hören (noch keine eigene Stimme). Öffnen Sie [Meine Stimmen](#) , drücken Sie [Stimmen aus dem Repository laden](#) (oder warten Sie einfach: Online-Stimmen erscheinen von selbst in der Liste) und laden Sie die „Offene Universalstimme“ (Englisch, Lizenz CC0 – für jede Nutzung frei). Gehen Sie zurück ins Studio, öffnen Sie [Ein Buch vertonen](#) , wählen Sie eine TXT-/FB2-/EPUB-Datei und die Stimme und drücken Sie [Vertonung starten](#) .

Ich möchte meine eigene Stimme. Nehmen Sie sich beim Vorlesen des Aufnahmeskripts auf (Abschnitt 6.1), öffnen Sie [Eigene Stimme trainieren](#) , wählen Sie Aufnahme und Skripttext, lassen Sie die Trainingsqualität auf „[Ausgewogen \(empfohlen\)](#)“ und drücken Sie [Stimme erstellen \(LoRA\)](#) . Bestätigen Sie nach dem Training die Einverständniskarte. Die Stimme steht nun unter [Meine Stimmen](#) und in [Ein Buch vertonen](#) bereit.

4 Das Studio (Startbildschirm)

Das Studio ist das erste Fenster. Es hat keine eigenen Einstellungen – es ist ein Menü aus drei großen Karten und einem Zahnrad.



Das Studio.

Element	Was es tut und wann Sie es benutzen
Titel und Untertitel	„Voxprint AI Audiobook Builder – Stimme trainieren, Bücher vertonen “. Nur zur Information.
Karte Ein Buch vertonen	Buch (TXT, FB2, EPUB) und Stimme wählen – fertiges Hörbuch mit Kapiteln erhalten. Öffnet das Vertonungsfenster. Das ist die Hauptkarte. Ist die Bibliothek leer, steht auf der Karte: „ Noch keine Stimme – trainieren Sie zuerst Ihre eigene oder importieren Sie eine unter „Meine Stimmen“. “ Während ein Buch vertont wird, steht dort „ Vertonung läuft... “
Karte Eigene Stimme trainieren	Aus einer Aufnahme einer Stimme (Ihrer eigenen oder der einer Person, die zugestimmt hat) und dem Text eine Stimme zum Vertonen machen. Öffnet das Trainingsfenster. Während des Trainings steht dort „ Training läuft... “



Element	Was es tut und wann Sie es benutzen
Karte Meine Stimmen	Ihre Stimmenbibliothek: anhören, Lizenzen, Import, Download, Löschen. Unten auf der Karte zeigt ein Zähler, wie viele Stimmen Sie haben (zum Beispiel „Stimmen in der Bibliothek: 3“).
Zahnrad (oben rechts)	Öffnet Einstellungen (Kapitel 8).
Hinweis unten	„ Verwenden Sie Stimmen verantwortungsvoll: nur mit Erlaubnis des Stimminhabers und unter Achtung seiner Rechte. Aufnahmen und Ergebnisse bleiben auf diesem Computer. “

Jedes andere Fenster hat oben links eine Schaltfläche **← Studio**, die Sie hierher zurückbringt. Schwere Arbeit (Training, Vertonung) läuft im Hintergrund weiter, wenn Sie zurückgehen.

5 Ein Buch vertonen

Öffnen Sie dieses Fenster über die Karte **Ein Buch vertonen**. Wählen Sie ein Buch und eine Stimme und drücken Sie Start. Fertige Teile werden laufend gespeichert – Sie können pausieren, beenden und später fortsetzen.

← Studio

Ein Buch vertonen

Wählen Sie ein Buch und eine Stimme und drücken Sie Start. Fertige Teile werden laufend gespeichert – Sie können pausieren, beenden und später fortsetzen.

1. Buch

Buch wählen...

The Lighthouse Keeper.txt

The Lighthouse Keeper
3 Kapitel · etwa 7 Min. Audio

2. Stimme

Demo-Sprecher

Nur persönliche Nutzung · custom/personal-only

Nur privat

Russian · Demo

Nur für den persönlichen Gebrauch: Vertonungen mit dieser Stimme nicht veröffentlichen oder verkaufen.

3. Text vorbereiten

Vollautomatisch – nichts zu bearbeiten oder zu prüfen. Erst Regeln, dann die optionale KI-Bereinigung, danach liest die Stimme das Ergebnis.

- ☒ **Layout aufräumen ★ empfohlen**
Verbindet umbrochene Zeilen und Worttrennungen, entfernt überflüssige Leerzeichen und unsichtbare Zeichen.
- ☒ **Fußnoten und Seitenzahlen entfernen ★ empfohlen**
Entfernt [1], ¹, Seitenzahlen und auf jeder Seite wiederholte Kopfzeilen.
- ☒ **Anführungszeichen und Striche vereinheitlichen ★ empfohlen**
Vereinheitlicht Anführungszeichen, Dialogstriche und Auslassungspunkte.
- ☒ **Links und E-Mail-Adressen kürzen ★ empfohlen**
Eine Webadresse wird als „Link“ gelesen statt buchstabiert.
- ☒ **Kapitelüberschriften korrigieren ★ empfohlen**
„KAPITEL XII“ wird zu „Kapitel zwölf“; Überschriften in GROSSBUCHSTABEN werden normal.
- ☒ **Zahlen ausschreiben ★ empfohlen**
Jahre, Daten, Prozent, Geld, Einheiten und Ordnungszahlen (russische und englische Bücher).
- ☒ **Abkürzungen ausschreiben ★ empfohlen**
„Dr.“, „etc.“, „z. B.“ werden ausgeschrieben (russische und englische Bücher).
- ☐ **KI: Tippfehler korrigieren und fehlende Kommas setzen ★ empfohlen**
Kleines Offline-Modell für Russisch; jede Änderung wird geprüft, nur sichere werden übernommen.
Nur für russische Bücher.

Das Vertonungsfenster, obere Hälfte: Buch, Stimme und Textvorbereitung (Demonstrationsstimme).

5.1 Schritt 1 – das Buch

Bedienelement	Was es tut
Buch wählen...	Öffnet einen Dateidialog. Unterstützt werden: <code>.txt</code> (UTF-8 oder cp1251; Überschriften wie „Kapitel 1“, „Chapter 1“ oder „Глава 2“ werden zu Kapiteln), <code>.fb2</code> und <code>.fb2.zip</code> , <code>.epub</code> . Titel, Autor und Cover werden gelesen, wenn vorhanden.
Dateiname und Infozeile	Nach der Auswahl zeigt Voxprint den Titel und „3 Kapitel · etwa 7 Min. Audio“ – Kapitelzahl und erwartete Länge. Vor der Auswahl steht dort „ Kein Buch gewählt (TXT, FB2, EPUB) “



Lässt sich die Datei nicht öffnen, erscheint eine Meldung wie „ **Nicht unterstütztes Buchformat.** **Verwenden Sie TXT, FB2 (oder FB2.ZIP) oder EPUB.** “ oder „ **Das Buch enthält keinen Text.** “ (siehe Kapitel „Fehlerbehebung“).

5.2 Schritt 2 – die Stimme

Die Auswahlliste unter **2. Stimme** zeigt die Stimmen Ihrer Bibliothek. Online-Stimmen, die noch nicht installiert sind, erscheinen als „ (herunterladen,)“; sie werden beim Start automatisch geladen und geprüft. Unter der Liste zeigt ein farbiges **Lizenz-Badge**, was Sie mit dem Ergebnis tun dürfen (siehe Kapitel 7 und das Glossar in Kapitel 9):

- grün – kommerzielle Nutzung erlaubt (zum Beispiel „CC-BY-4.0 · kommerzielle Nutzung erlaubt“ und „Kommerziell“);
- bernsteinfarben – eingeschränkt („Nur persönliche Nutzung · ...“, „Nur privat“, „Öffentlich, nichtkommerziell“).

Unter dem Badge wiederholt ein Hinweis die Einschränkung, zum Beispiel: „ **Nur für den persönlichen Gebrauch: Vertonungen mit dieser Stimme nicht veröffentlichen oder verkaufen.** “ Haben Sie noch gar keine Stimmen, sagt das Fenster „ **Sie haben noch keine Stimmen. Trainieren Sie Ihre eigene Stimme oder fügen Sie unter „Meine Stimmen“ eine hinzu.** “ und bietet die Schaltflächen **Eigene Stimme trainieren** und **Meine Stimmen** an.

5.3 Schritt 3 – Text vorbereiten

„ **Vollautomatisch – nichts zu bearbeiten oder zu prüfen. Erst Regeln, dann die optionale KI-Bereinigung, danach liest die Stimme das Ergebnis.** “ Nichts wird zur Prüfung angezeigt, und Ihre Buchdatei wird nie verändert. Alle regelbasierten Schritte sind standardmäßig angehakt; nehmen Sie den Haken bei dem heraus, was Sie nicht wollen.

Kontrollkästchen	Was es tut
Layout aufräumen	Verbindet umbrochene Zeilen und Worttrennungen, entfernt überflüssige Leerzeichen und unsichtbare Zeichen.
Fußnoten und Seitenzahlen entfernen	Entfernt [1], ¹ , Seitenzahlen und auf jeder Seite wiederholte Kopfzeilen.
Anführungszeichen und Striche vereinheitlichen	Vereinheitlicht Anführungszeichen, Dialogstriche und Auslassungspunkte.
Links und E-Mail-Adressen kürzen	Eine Webadresse wird als „Link“ gelesen statt buchstabiert.
Kapitelüberschriften korrigieren	„KAPITEL XII“ wird zu „Kapitel zwölf“; Überschriften in GROSSBUCHSTABEN werden normal.
Zahlen ausschreiben	Jahre, Daten, Prozent, Geld, Einheiten und Ordnungszahlen (russische und englische Bücher).
Abkürzungen ausschreiben	„Dr.“, „etc.“, „z. B.“ werden ausgeschrieben (russische und englische Bücher).
KI: Tippfehler korrigieren und fehlende Kommas setzen	Kleines Offline-Modell für Russisch; jede Änderung wird geprüft, nur sichere werden übernommen. Es braucht einen einmaligen Download (eine Schaltfläche Herunterladen erscheint; das Modell ist etwa 365 MB groß) und gilt nur für russische Bücher.

Kontrollkästchen	Was es tut
► Weitere Vorbereitung (bald)	Ausgegraute Ideen für spätere Versionen: Pausen und Zeichensetzung per KI, russische Betonungszeichen, Übersetzung vor der Vertonung, verschiedene Stimmen für Figuren. Sie sind mit „ bald “ markiert und tun noch nichts.

Die Regeln decken Russisch und Englisch vollständig ab. Für andere Sprachen (zum Beispiel deutsche Bücher) werden nur die sprachneutralen Schritte angewendet – Layout, Fußnoten, Anführungszeichen, Links.

5.4 Schritt 4 – Ausgabeformat und Qualität

► Weitere Vorbereitung (bald)

4. Ausgabeformat

☒ Eine Opus-Datei mit Kapiteln (.opus) – empfohlen
Offen, lizenzfrei und klein. Spielt in VLC, Audiobookshelf und Android-Apps wie Voice.
Kostenlose Player: VLC, Audiobookshelf, Voice (Android), Smart AudioBook Player (Android). Die Kapitelunterstützung hängt vom Player ab.

☐ Ordner mit MP3-Dateien, eine pro Kapitel
Am kompatibelsten: jeder Player, jedes Auto, Handy und jeder Lautsprecher. Mit Playlist und Cover.

☐ M4B (AAC) mit Kapiteln – für Apple Books
Spielt in Apple Books, auf iPhone/Mac und in den meisten Hörbuch-Apps.

M4B (AAC) für Apple Books – verwendet den AAC-Codec, der patentbelastet und nicht vollständig offen ist; Sie wählen ihn nach eigenem Ermessen.

Qualität

Kompakt

Standard

Hoch

Saubere Sprache, kleine Dateien – empfohlen. Etwa Opus 14 MB pro Stunde Audio.

► Weitere Formate

Pausen normal (Satz 430 ms, Absatz 1050 ms)

Nach jedem Komma, Satz, jeder Auslassung, jedem Gedankenstrich, Absatz, Szenenwechsel und Kapitel wird Stille exakter Länge eingefügt, unabhängig davon, wie das Stimmmodell den Text phrasiert, damit die Pausen deutlich hörbar sind. „Normal“ ist etwas länger als die frühere Vertonung. Eine spätere Änderung verwendet bereits gesprochene Textteile weiter.

► Erweitert

Vertonung starten

Wählen Sie ein Buch und eine Stimme.

Die Vertonung läuft auf Ihrem Computer. Verwenden Sie nur Stimmen, die Sie nutzen dürfen.

Das Vertonungsfenster, untere Hälfte: Ausgabeformat, Qualität, Fortschritt und Mini-Player.

4. Ausgabeformat – wählen Sie eines:

Format	Was Sie erhalten	Wo es abspielbar ist
Eine Opus-Datei mit Kapiteln (.opus) – empfohlen	eine Datei <code>Autor - Titel.opus</code> mit Kapitelmarken	Offen, lizenzfrei und klein. Spielt in VLC, Audiobookshelf und Android-Apps wie Voice.



Format	Was Sie erhalten	Wo es abspielbar ist
Ordner mit MP3-Dateien, eine pro Kapitel	ein Ordner mit <code>NN - Kapitel.mp3</code> , eine Wiedergabeliste und ein Cover	Am kompatibelsten: jeder Player, jedes Auto, Handy und jeder Lautsprecher. Mit Playlist und Cover.
M4B (AAC) mit Kapiteln – für Apple Books	eine <code>.m4b</code> -Datei mit Kapiteln	Spielt in Apple Books, auf iPhone/Mac und in den meisten Hörbuch-Apps.

Bei M4B erscheint ein gelber Patenthinweis: „ **M4B (AAC) für Apple Books – verwendet den AAC-Codec, der patentbelastet und nicht vollständig offen ist; Sie wählen ihn nach eigenem Ermessen.** “ Kurz gesagt: AAC ist patentbehafet, Voxprint gewährt dafür keine Patentlizenz, und für die Einhaltung der Gesetze bei Wahl dieses Formats sind allein Sie verantwortlich. Brauchen Sie Apple Books nicht, nutzen Sie es nicht.

► **Weitere Formate** (eingeklappt) enthält weitere Formate: **M4B-Container mit Opus-Audio**, **Ordner mit Opus-Dateien, eine pro Kapitel**, **Eine MP3-Datei mit Kapitelmarken**, **Ordner mit FLAC-Dateien (verlustfreies Archiv)**, **Ordner mit WAV-Dateien (verlustfreies Archiv)**.

Qualität – drei Schaltflächen, die die Bitrate festlegen (die Datenmenge pro Sekunde Ton – mehr Daten bedeuten besseren Klang und größere Dateien):

Schaltfläche	Bedeutung	Opus / MP3 / AAC	Etwa pro Stunde Audio
Kompakt	Kleinste Dateien; die Sprache bleibt klar.	24 / 64 / 48 kbit/s	11 / 29 / 22 MB
Standard	Saubere Sprache, kleine Dateien – empfohlen.	32 / 96 / 64 kbit/s	14 / 43 / 29 MB
Hoch	Mehr Reserve für Kopfhörer und laute Umgebungen.	48 / 128 / 96 kbit/s	22 / 58 / 43 MB

Pausen – ein Regler mit fünf Stufen, von **deutlich kürzer** über **normal** (Standard) bis **deutlich länger**. Voxprint schneidet den Text an jedem Komma, Satzende, jeder Auslassung, jedem Gedankenstrich, Absatz, Szenenwechsel und Kapitelende und fügt dort **Stille exakter Länge** ein, sodass die Pausen hörbar sind, egal wie das Stimmmodell den Text phrasiert. Bei **normal** folgen auf einen Satz 430 ms, auf einen Absatz 1,05 s und auf ein Kapitel 1,9 s – etwas länger als in früheren Versionen; jede Art hat ihre eigene Länge (Komma 240 ms, Auslassung 680 ms, Gedankenstrich 320 ms, Szenenwechsel 1,9 s), der Regler skaliert alle. Die Wahl wird gespeichert. Ändert man sie für ein bereits vertontes Buch, werden die gespeicherten Fragmente neu zusammengefügt statt erneut gesprochen, solange die Textteile gleich bleiben.

► **Erweitert** (eingeklappt) enthält: die genauen Bitraten je Format (ändern Sie eine, wird die Qualität „benutzerdefiniert“: keine Schaltfläche ist hervorgehoben); **Ausgabeordner...** – den Ordner, in dem das Hörbuch abgelegt wird; das Kontrollkästchen **Kapitelüberschriften vorlesen**; und das schreibgeschützte Feld „ **Beispiel für den vorbereiteten Text (erster Absatz)** “, das zeigt, wie der erste geänderte Absatz nach der Vorbereitung aussieht.

5.5 Starten, pausieren, anhalten

Bedienelement	Was es tut
Vertonung starten	Startet die Vertonung. Beim ersten Start wird das Stimmmodell geladen („ Stimmenmodell wird geladen... “).

Bedienelement	Was es tut
Pause / Fortsetzen	Pause greift nach dem aktuellen Fragment; danach heißt dieselbe Schaltfläche „Fortsetzen“.
Abbrechen	Beendet den Auftrag. Fertige Fragmente bleiben gespeichert.
Fortschrittsbalken und Statuszeile	z. B. „Fragment 3 von 8 · noch etwa 7 Min.“ – wie viele Stücke (Fragmente) des Buches fertig sind und wie lange es etwa noch dauert.
Ergebnisordner öffnen	Erscheint am Ende („ Fertig “): öffnet den Ordner mit dem fertigen Hörbuch.

Fortsetzbar. Jedes fertige Fragment wird auf der Festplatte gespeichert. Haben Sie pausiert, abgebrochen, ist das Programm abgestürzt oder haben Sie es geschlossen, drücken Sie später erneut **Vertonung starten** : „ **Es geht weiter: ... Fragmente waren bereits fertig.** “ Nach erfolgreichem Abschluss werden die gespeicherten Fragmente gelöscht.

Zuhören, während es entsteht. Sobald die ersten Fragmente fertig sind, erscheint der **Mini-Player** („ **Bisheriges Ergebnis anhören** “): eine Schaltfläche „ **Abspielen** “ / „ **Pause** “, ein Schieberegler und die Zeit. „ **Hörbar: ... von ... Teilen fertig. Neue Teile kommen laufend hinzu.** “ Er folgt neuen Fragmenten und wartet, wenn er die Vertonung eingeholt hat. Ist der Auftrag zu Ende, wird das gesamte Ergebnis seine Wiedergabeliste.

Nach erfolgreichem Abschluss sehen Sie „ **Fertig.** “ und je nach Lizenz der Stimme einen Hinweis, zum Beispiel: „ **Hinweis: Diese Stimme ist nur privat – behalten Sie das Hörbuch auf Ihrem Computer, nicht veröffentlichen oder verkaufen.** “

5.6 Geschwindigkeit

Die Vertonung nutzt **gebündelte Erzeugung (Batch)**: Mehrere Fragmente durchlaufen das Stimmmodell in einem Aufruf statt einzeln. Die Batch-Größe richtet sich nach dem freien Videospeicher (bis zu 12) und wird automatisch halbiert, wenn der Speicher knapp wird; scheitert ein Batch aus anderem Grund, fällt Voxprint auf Fragment-für-Fragment zurück – das Bündeln kann also nie dazu führen, dass ein Buch scheitert. Fertige Fragmente speichert ein Hilfsthread, während die Grafikkarte schon den nächsten Batch erzeugt.

Gemessen auf einer RTX 4090 (12 englische Fragmente, 80 s Audio, offene Stimme): Der frühere Modus brauchte einen Echtzeitfaktor (RTF) von **3,05** (243 s Arbeit für 80 s Ton); mit Batch 12 sind es **0,31** (25 s) – etwa **10-mal schneller**. RTF heißt „Sekunden Arbeit pro Sekunde Audio“: 0,31 bedeutet, dass eine Stunde Hörbuch etwa 19 Minuten dauert. Richtwerte bei RTF 0,31–0,5: 5 Stunden Audio $\approx$ 1,6–2,5 Stunden Arbeit; 20 Stunden $\approx$ 6–10 Stunden. Auf Karten mit 12–16 GB ist der Batch kleiner, die Geschwindigkeit also geringer.

6 Eigene Stimme trainieren

6.1 Die Stimme aufnehmen

Die Qualität der Stimme hängt vor allem von der Aufnahme ab. Planen Sie **5 bis 15 Minuten** saubere Sprache (unter 2 Minuten löst eine Warnung aus; unter 10 Sekunden wird abgelehnt). Das Programm enthält keinen Rekorder – nehmen Sie ein beliebiges Aufnahmegerät oder eine Handy-App und speichern Sie als WAV, FLAC, MP3, M4A oder OGG.

Vor der Aufnahme: ein ruhiger Raum, das Mikrofon etwa eine Handbreit vom Mund entfernt, keine Klang-„Verbesserungen“ (Rauschunterdrückung, Equalizer, Hall), gleichmäßige Lautstärke.

Das Aufnahmeskript. Das Repository enthält ein fertiges Skript, [docs/voice-script-ru-v3.txt](#) (Russisch; es hat auch englische und deutsche Passagen). Es besteht aus 18 Blöcken: Begrüßung, Zahlen und Daten, Laute der Sprache, neutrales Lesen, Ruhe, Freude, Traurigkeit, Ärger, Überraschung, Flüstern und Lautes, drei kurze Geschichten, optional Englisch und ein Fachbegriff-Block, ein optionaler Block nur für Erwachsene und – ganz am Ende – die Einverständniserklärung. Das Skript selbst nennt drei einfache Regeln:

1. **Lesen Sie nur gewöhnliche Zeilen.** Alles in eckigen Klammern und alle Zeilen mit `===` sind Hinweise – nicht vorlesen.
2. **Eine Zeile – ein Satz.** Lesen, atmen, eine Sekunde schweigen, dann die nächste Zeile.
3. **Verhaspelt? Eine Sekunde schweigen und denselben Satz noch einmal von vorn lesen.** Die Aufnahme muss nicht gestoppt werden.

Weitere Hinweise aus dem Skript: Gefühle müssen nicht gespielt werden – es genügt, die Stimme ein wenig zu verändern, und wenn es nicht klappt, lesen Sie in normaler Stimme. Mit „OPTIONAL“ gekennzeichnete Blöcke dürfen übersprungen werden. Genau diese Skriptdatei wählen Sie im Trainingsfenster als „Text“.

Voxprint ist darauf ausgelegt, wiederholt gelesene Sätze zu verkraften: Beim Abgleich der Aufnahme mit dem Skript wird für jede Zeile die beste Lesung behalten. Dennoch gilt: Je sauberer die Aufnahme, desto besser die Stimme.

Die Einverständniserklärung (Block 18). Beenden Sie die Aufnahme mit **einem** der Einverständnissätze – dem, der für Sie zutrifft: *kommerziell* (A), *öffentlich nichtkommerziell* (B) oder *nur privat* (C), auf Russisch, Englisch oder Deutsch. Sagen Sie anstelle der Wörter in eckigen Klammern Ihren eigenen Namen und das heutige Datum. Lesen Sie ihn nur, wenn die Stimme Ihre ist oder Sie die Erlaubnis des Inhabers haben. Einzelheiten in Abschnitt 6.6.

6.2 Das Trainingsfenster

Öffnen Sie es über die Karte [Eigene Stimme trainieren](#). [Ihre Stimme aus einer Aufnahme mit einem Klick. Wählen Sie die Aufnahme und den Text, den Sie gelesen haben.](#)

Studio
Train your voice

Your voice from a recording in one click. Choose the recording and the text you read.

Choose audio71 audio file(s) chosen

☒ I have no transcript - recognise the speech automatically

Choose a folder with clips...

Automatic speech recognition can make mistakes, and the result is not guaranteed: wrong words in the text teach the voice wrong sounds. Clips the program is unsure about are skipped, but please use clear recordings of one speaker. You can pick many files (or a folder) at once, or drop them here.

☒ I understand that the text will be recognised automatically and may contain errors

Training qualityBalanced (recommended)

The automatic choice for your recording and graphics card. Good likeness in reasonable time.

Estimated training time: about 2 min on NVIDIA GeForce RTX 4090 (5 passes, adapter size 32, about 71 clips).

► Advanced

Voice owner's consent

Read it from the spoken statement at the end of my recording (recommended)

End your recording with one of the three consent sentences from the recording script (it says your name, the date and what is allowed). The program recognises it and shows what it understood - you confirm with one click. If it is unclear, the strictest level (private only) is used. This is a record of what you said, not legal advice.

☒ Keep the spoken statement with the voice

Create voice (LoRA)

The small adapter (tens of MB) works only in a few apps, e.g. Alexandria.

Quick preview...

☐ Compare 2 variants

☒ Check the voice after training (recommended)

Quick preview: about 60 s (1 short training run(s) on a few clips, then a ~10 s sample with automatic checks).

Voice type: not set

Optional description of the voice (saved in voice.json)

Build universal model (~4 GB)

The ~4 GB merged model is universal: it works in any app that runs Qwen3-TTS.

Create dataset

0%

UpdatesLoading modelAlignmentSlicingLoRA trainingSaving

Choose the audio and the text - I will do the rest.

Das Trainingsfenster mit eingeschaltetem Modus „kein Text“ (englische Oberfläche). (Screenshot der englischen Oberfläche)

Bedienelement	Was es tut und wann Sie es benutzen
Audio wählen	Wählen Sie die Stimmaufnahme (die Datei lässt sich auch ins Fenster ziehen). Vor der Auswahl: „ Keine Datei gewählt (kann ins Fenster gezogen werden) “
Text wählen	Wählen Sie die Textdatei, die Sie gelesen haben (<code>.txt</code>), UTF-8; zum Beispiel das Aufnahmeskript). Vor der Auswahl: „ Keine Datei gewählt (txt, UTF-8) “ Im Modus „kein Text“ wird diese Zeile zu „ Skript (optional): der vorgelesene Text... “ (optional).
Kontrollkästchen „ Ich habe keinen Text – Sprache automatisch erkennen “	Nur Audio, ohne Text: siehe Abschnitt 6.4.
Trainingsqualität	Auswahlliste der Trainingsstufen: siehe Abschnitt 6.3. Darunter zeigt das Programm eine kurze Beschreibung und eine Schätzung der Trainingszeit für Ihre Grafikkarte.
► Erweitert	Zeigt die Zahlen von Hand (nur bei „ Manuell “ änderbar).

Bedienelement	Was es tut und wann Sie es benutzen
Einverständnis der Stimminhaberin / des Stimminhabers	Wie die Erlaubnis des Stimminhabers festgehalten wird: siehe Abschnitt 6.6.
Stimme erstellen (LoRA)	Die Hauptschaltfläche: richtet die Aufnahme aus, schneidet sie, trainiert die Stimme und legt sie in Ihrer Bibliothek ab.
Schnelle Vorschau... und Kontrollkästchen 2 Varianten vergleichen	Ein schneller Hör- und Vergleichstest vor dem langen Lauf: Abschnitt 6.5.
Kontrollkästchen „ Stimme nach dem Training prüfen (empfohlen) “	Nach dem Training lässt Voxprint die neue Stimme einen Testsatz sprechen und prüft Tonhöhe und Verständlichkeit automatisch. Eingeschaltet lassen.
Auswahl des Stimmtyps	Optional: „ Männliche Stimme “, „ Weibliche Stimme “, „ Kinderstimme “, „ Andere Stimme “ oder „ Stimmtyp: nicht angegeben “. Wird mit der Stimme gespeichert.
Beschreibungsfeld	„ Optionale Beschreibung der Stimme (wird in voice.json gespeichert) “
Universalmodell erstellen (~4 GB)	Führt den trainierten Adapter zu einem eigenständigen Modellordner zusammen, der in jeder App mit Qwen3-TTS funktioniert (Abschnitt 6.7).
Datensatz erstellen	Bereitet nur den Datensatz vor (ausgerichtete und geschnittene Clips), ohne Training. Nützlich, wenn Sie woanders trainieren wollen.
Fortschrittsbalken und Etappen	Modell laden , Ausrichtung , Zerschneiden , LoRA-Training , Speichern – die laufende Etappe ist hervorgehoben. Während ein Auftrag läuft, erscheint Abbrechen .
Statuszeile	Zu Beginn: „ Wählen Sie Audio und Text - den Rest erledige ich. “
Zahnrad (oben rechts)	Öffnet „ Einstellungen “.

Ist der Auftrag beendet, zeigt die Statuszeile „ **Die Stimme wurde zu „Meine Stimmen“ hinzugefügt.** “ und eine Schaltfläche **Ergebnisordner öffnen** erscheint. Der Adapterordner ist `... \output\<Stimmennamen>` (einige zehn MB); der Datensatz liegt in `... \<Name der Aufnahme> \Voxprint\dataset`.

Im Standardmodus (mit Text) stehen die beiden Schaltflächen **Audio wählen** und **Text wählen** untereinander, jeweils mit dem Namen der gewählten Datei, und der Block „kein Text“ mit der Warnung ist ausgeblendet. (Für diesen Standardzustand gibt es keinen eigenen Screenshot; das Bild oben zeigt den Modus „kein Text“, der alle übrigen Bedienelemente enthält.)

6.3 Trainingsstufen

Unter **Trainingsqualität** gibt es vier Stufen. Zu jeder zeigt das Programm, was sie bedeutet, und eine **geschätzte Zeit**, zum Beispiel „Geschätzte Trainingszeit: etwa 2 Min. auf NVIDIA GeForce RTX 4090 (5 Durchläufe, Adaptergröße 32, etwa 71 Clips)“. Lesen Sie die Schätzung als „ungefähr“.

Stufe	Bedeutung
Schnell	Ein schneller Versuch: weniger Durchläufe und ein kleinerer Adapter. Die Stimme ist erkennbar, Feinheiten sind größer.



Stufe	Bedeutung
Ausgewogen (empfohlen)	Die automatische Wahl für Ihre Aufnahme und Grafikkarte. Gute Ähnlichkeit in vernünftiger Zeit.
Maximum	Der längste Lauf: etwa doppelt so viele Durchläufe und ein größerer Adapter. Beste Chance auf eine nahe Stimme, dauert aber am längsten und kann bei kurzen Aufnahmen überanpassen.
Manuell	Sie wählen die Werte selbst (siehe Erweitert). Ändern Sie sie nur, wenn Sie wissen, wofür sie stehen.

Unter **Erweitert** sehen Sie die Zahlen hinter einer Stufe:

Feld	In einfachen Worten
Durchläufe der Aufnahme (Epochen)	Wie oft das Training Ihre ganze Aufnahme durchläuft. Mehr Durchläufe: näher an der Stimme, aber zu viele können sie „brabbeln“ lassen.
Adaptergröße (LoRA-Rang)	Wie groß das Stimm-Add-on ist. Größer – mehr Details, mehr Speicher.
Adapterstärke (LoRA-Alpha)	Wie stark das Add-on das Basismodell beeinflusst.
Lernrate	Wie groß jeder Lernschritt ist. Die empfindlichste Zahl: nicht erhöhen, wenn Sie den Grund nicht kennen.
Schritte pro Update (Gradientenakkumulation)	Wie viele kleine Schritte zusammengezählt werden, bevor das Modell aktualisiert wird (spart Speicher).

„Nur im Modus Manuell änderbar. Hohe Lernraten und viele Durchläufe können die Trainingszahl senken, aber die Stimme beginnt zu plappern und hört nicht auf – der automatische Wert ist am sichersten.“ Keine Stufe erhöht jemals die Lernrate. In unseren Tests bedeutete eine niedrigere „Trainingszahl“ (Loss) keine bessere Stimme – hören Sie das Ergebnis immer an.

6.4 Kein Text? (nur Audio)

Haken Sie „**Ich habe keinen Text – Sprache automatisch erkennen**“ an, und das Programm erkennt die Sprache selbst (Qwen3-ASR, offline; das Erkennungsmodell, etwa 1,9 GB, wird bei der ersten Nutzung geladen). Die Textzeile bleibt als **optionales Skript** („**Skript (optional): der vorgelesene Text...**“, oder ziehen Sie eine `.txt` ins Fenster): Wählen Sie den vorgelesenen Text, wird jedes erkannte Stück tolerant damit abgeglichen (Versprecher und wiederholte Zeilen werden berücksichtigt), sodass der richtige Text statt des erkannten verwendet wird. Außerdem haben Sie:

- **Audio wählen** – jetzt können Sie **viele Dateien** auf einmal wählen; die Zeile zeigt „N Audiodatei(en) gewählt“;
- **Ordner mit Aufnahmen wählen...** – einen ganzen Ordner mit Clips, samt Unterordnern;
- Ziehen und Ablegen von Dateien ins Fenster.

Jede Datei wird einzeln erkannt; lange Aufnahmen werden an Pausen in Stücke von bis zu 14 s geschnitten; alles wird zu einem Datensatz zusammengeführt und auf gleiche Lautstärke gebracht. Automatisch übersprungen werden: Clips unter 1,5 s oder über 20 s, leere oder unplausible Erkennung, Duplikate und Clips mit schlechtem Klang. Am Ende meldet das Fenster zum Beispiel „N Datei(en) erkannt: X von Y Clips behalten = ... von ... Min. Audio“.

„ Die automatische Spracherkennung kann Fehler machen, das Ergebnis ist nicht garantiert: falsche Wörter im Text bringen der Stimme falsche Laute bei. Unsichere Clips werden übersprungen, verwenden Sie aber klare Aufnahmen einer einzelnen Person. Sie können viele Dateien (oder einen Ordner) auf einmal wählen oder hierher ziehen. “

Deshalb müssen Sie „ **Ich verstehe, dass der Text automatisch erkannt wird und Fehler enthalten kann** “ anhaken, bevor die Schaltflächen funktionieren (der Haken wird bei jedem Einschalten des Modus zurückgesetzt).

6.5 Schnelle Vorschau und Vergleich zweier Varianten

Vor einem langen Lauf können Sie Einstellungen günstig testen. **Schnelle Vorschau...** trainiert einen sehr kurzen Adapter an wenigen Clips (höchstens 12 Clips und 4 Durchläufe, etwa höchstens 3 Minuten) und erzeugt dann eine Probe von etwa 10 Sekunden, die Sie im Player anhören können. Die Schätzung steht neben der Schaltfläche: „ **Schnelle Vorschau: etwa ... (... kurzes Training mit wenigen Clips, danach eine ~10-s-Probe mit automatischer Prüfung).** “

The small adapter (tens of MB) works only in a few apps, e.g. Alexandria.

Quick preview...

☒ Compare 2 variants

☒ Check the voice after training (recommended)

Quick preview: about 2 min (2 short training run(s) on a few clips, then a ~10 s sample with automatic checks).

Listen
0:00 / 0:14

Play

Variant A: 4 passes, adapter size 32 - sample 22 s, recognition errors 15 %, pitch vs. your recording -0.7 semitones - looks good

Play

Use these settings

Variant B: 6 passes, adapter size 64 - sample 32 s, recognition errors 15 %, pitch vs. your recording +1.2 semitones - looks good

Play

Use these settings

Schnelle Vorschau zweier Varianten: Player und automatische Messwerte (englische Oberfläche). (Screenshot der englischen Oberfläche)

- Ist **2 Varianten vergleichen** angehakt, entstehen zwei Proben: A mit den aktuellen Einstellungen und B mit einem größeren Adapter und dem 1,5-fachen der Durchläufe.
- Jede Variante erhält eine Zeile automatischer Messwerte: die Länge der Probe, „Erkennungsfehler“ (wie viele Wörter ein automatischer Zuhörer beim Wiedererkennen der Probe falsch verstanden hat – je niedriger, desto besser) und „Tonhöhe gegenüber Ihrer Aufnahme“ in Halbtönen (wie viel höher oder tiefer die Stimme als Ihre ist – am besten nahe 0). Danach folgt ein Urteil: „ **sieht gut aus** “ oder eine Warnung.
- Abspielen** spielt eine Variante ab. **Diese Einstellungen verwenden** übernimmt ihre Zahlen in die Stufe „ **Manuell** “; drücken Sie dann **Stimme erstellen (LoRA)** für den vollen Lauf.
- Eine Vorschau-Stimme ist vorläufig und wird **nicht** zu **Meine Stimmen** hinzugefügt. Die Messwerte sind ein Hinweis, kein Urteil: Hören Sie immer selbst zu.


6.6 Die Einverständniskarte

Jede Stimme trägt einen Vermerk darüber, was ihr Inhaber erlaubt. Wählen Sie unter **Einverständnis der Stimminhaberin / des Stimminhabers**, wie er festgelegt wird:

Option	Wann Sie sie benutzen
Aus der gesprochenen Erklärung am Ende meiner Aufnahme lesen (empfohlen)	Sie haben die Aufnahme mit einem der drei Einverständnissätze beendet (Block 18 des Skripts). Nach dem Training erkennt das Programm die Erklärung und zeigt das Ergebnis.
Ich wähle den Umfang selbst	Sie tippen den Namen der sprechenden Person (Platzhalter „ Name der sprechenden Person “) und wählen den Umfang selbst. Nur für die eigene Stimme oder mit Erlaubnis des Inhabers.
Keine Erklärung: nur private Nutzung	Keine Erklärung. Die Stimme wird als <i>nur privat</i> gekennzeichnet.

Das Kontrollkästchen **Gesprochene Erklärung bei der Stimme aufbewahren** speichert die gesprochene Erklärung (die letzten 45 Sekunden der Aufnahme) neben der Stimme.

Nach dem Training im automatischen Modus erscheint die **Einverständniskarte**:



Die Einverständniskarte nach dem Training: erkannter Name, Datum und Umfang sowie die Schaltfläche „Bestätigen“ (englische Oberfläche). (Screenshot der englischen Oberfläche)

Sie zeigt den *erkannten* Namen, das Datum und den Umfang sowie den erkannten Satz. Prüfen Sie ihn, ändern Sie bei Bedarf den Umfang in der Auswahlliste und drücken Sie **Bestätigen**. Ist die Erklärung undeutlich oder fehlt sie, gilt die strengste Stufe – „**Nur privat**“. Das ist ein Vermerk dessen, was gesagt wurde, **keine Rechtsberatung**.

Umfang in der Auswahlliste	Badge	Bedeutung	Gespeicherte Lizenz
Kommerziell: Hörbücher dürfen verkauft werden	Kommerziell	Die Stimminhaberin / der Stimminhaber hat kommerzielle Nutzung erlaubt: Hörbücher mit dieser Stimme dürfen verkauft werden.	CC-BY-4.0
Öffentlich, nichtkommerziell: frei veröffentlichen, nicht verkaufen	Öffentlich, nichtkommerziell	Hörbücher mit dieser Stimme dürfen kostenlos veröffentlicht, aber nicht verkauft werden.	CC-BY-NC-4.0
Nur privat: Ergebnisse bleiben auf diesem Computer	Nur privat	Hörbücher mit dieser Stimme müssen auf Ihrem Computer bleiben; nicht veröffentlichen oder verkaufen.	custom/ personal-only


6.7 Das Universalmodell (optional)

Der kleine Adapter (einige zehn MB) funktioniert nur in wenigen Apps (zum Beispiel Alexandria).

Universalmodell erstellen (~4 GB) führt ihn zu einem eigenständigen Modellordner (`merged_model`) zusammen, der in **jeder** App mit Qwen3-TTS funktioniert. Voxprint prüft den freien Speicherplatz und fragt zuerst nach („**Universalmodell erstellen**“); es wird nie automatisch erstellt. Solange keine Stimme erstellt wurde, ist die Schaltfläche deaktiviert. Einzelheiten stehen in `USAGE.txt` im Ordner.

7 Meine Stimmen

Öffnen Sie das Fenster über die Karte **Meine Stimmen**. Stimmen werden auf diesem Computer gespeichert. Jede Stimme hat eine Lizenz, die festlegt, wofür die Vertonung genutzt werden darf.



The screenshot shows the 'Meine Stimmen' (My Voices) interface. At the top, there's a navigation bar with a back arrow and 'Studio', and a title 'Meine Stimmen'. Below the title, a message states: 'Stimmen werden auf diesem Computer gespeichert. Jede Stimme hat eine Lizenz, die festlegt, wofür die Vertonung genutzt werden darf.' (Voices are saved on this computer. Each voice has a license that specifies for what the recording can be used). Below this are three buttons: 'Stimme importieren...' (Voice import...), 'Stimmen aus dem Repository laden' (Load voices from the repository), and 'Liste aktualisieren' (Update list).

There are three voice cards displayed:

- Demo-Sprecher**: License badges: 'Nur persönliche Nutzung · custom/personal-only' (yellow) and 'Nur privat' (yellow). Details: Russian · 10 Min. Sprache · 15 Epochen · Männliche Stimme · von Demo. Description: Warm narrator voice, calm pace. Buttons: ▶ Anhören, Mit dieser Stimme vertonen, Details..., Löschen.
- Marta**: License badges: 'CC-BY-4.0 · kommerzielle Nutzung erlaubt' (green) and 'Kommerziell' (green). Details: English · 9 Min. Sprache · 12 Epochen · Weibliche Stimme · von Demo. Description: Bright, friendly storyteller. Buttons: ▶ Anhören, Mit dieser Stimme vertonen, Details..., Löschen.
- Old Radio**: License badges: 'Nur persönliche Nutzung · CC-BY-NC-4.0' (yellow) and 'Öffentlich, nichtkommerziell' (yellow). Details: English · 15 Min. Sprache · 20 Epochen · Andere Stimme · von Demo. Description: Vintage radio announcer. Buttons: ▶ Anhören, Mit dieser Stimme vertonen, Details..., Löschen.

Meine Stimmen: drei Stimmenkarten (Demonstrationsstimmen) mit Lizenz- und Umfang-Badges.

Jede Stimme ist eine Karte:

Element	Bedeutung
Name und zwei Badges	Das Lizenz-Badge (grün „... · kommerzielle Nutzung erlaubt“ oder bernsteinfarben „Nur persönliche Nutzung · ...“) und das Umfang-Badge (Kommerziell , Öffentlich, nichtkommerziell , Nur privat).
Infozeile	Sprache · Minuten Sprache im Training · Epochen (Durchläufe) · Stimmtyp · Autor · (bei Online-Stimmen) Größe.
Beschreibung	Was der Autor geschrieben hat. Bei einer Stimme „nur zum Testen“ steht zusätzlich eine Warnung.
Anhören	Spielt eine kurze Probe der Stimme. Stopp hält sie an. Hat die Stimme keine Probe: „ Diese Stimme hat keine Hörprobe “
Mit dieser Stimme vertonen	Öffnet das Vertonungsfenster mit bereits gewählter Stimme.




Element	Bedeutung
Details...	Öffnet „ Stimmendetails “: Name , Autor (wessen Stimme es ist) , Lizenz der Stimme , Stimmtyp , Beschreibung . Drücken Sie Speichern .
Löschen	Löscht die Stimme nach Rückfrage von diesem Computer: „ Die Stimme „...“ von diesem Computer löschen? Das kann nicht rückgängig gemacht werden. “

Die Fußzeile des Fensters wiederholt: „ **Die Lizenz gilt nur für das Stimmenmodell. Verwenden Sie eine Stimme nur mit Erlaubnis ihres Inhabers und im Rahmen ihrer Lizenz (z. B. CC BY-NC = nur private Nutzung); für die rechtmäßige Verwendung sind Sie verantwortlich.** “

Ist die Bibliothek leer, sagt das Fenster „ **Noch keine Stimmen. Trainieren Sie Ihre eigene Stimme aus einer Aufnahme, importieren Sie einen Stimmenordner oder eine .zip-Datei oder laden Sie Stimmen aus dem Repository.** “ und bietet **Eigene Stimme trainieren** an.

7.1 Online-Stimmen und das Stimmen-Repository



Stimmen, die online verfügbar, aber noch nicht installiert sind, haben eine Schaltfläche „Herunterladen“ (Demonstrationsdaten; englische Oberfläche). (Screenshot der englischen Oberfläche)

- Stimmen aus dem Online-Index erscheinen von selbst als Karten mit dem Zustand „**Noch nicht heruntergeladen**“, ihrer Lizenz, der Größe und einer Schaltfläche **Herunterladen**. Der Download wird per SHA-256-Prüfsumme kontrolliert und kann fortgesetzt werden.
- **Liste aktualisieren** lädt die Liste neu. Ohne Verbindung zeigt Voxprint die zuletzt bekannte Liste („**Keine Verbindung - zuletzt bekannte Liste der Online-Stimmen.**“).
- **Stimmen aus dem Repository laden** öffnet den Dialog „**Stimmen-Repository**“ mit **Aktualisieren**, einem Feld für die Adresse des Index (`index.json`) und **Auswahl herunterladen**.

7.2 Eine Stimme importieren

Stimme importieren... bietet zwei Wege: **Aus einem Ordner...** (ein Adapterordner) und **Aus einer .zip-Datei...** (ein Stimmpaket). Archive werden auf unsichere Pfade und Größenlimits geprüft. Eine Stimme ohne angegebene Lizenz gilt als „nur persönliche Nutzung“.

7.3 Lizenzen und die Stimme, die Voxprint anbietet

Lizenz	Kommerzielle Nutzung
CC0-1.0, CC-BY-4.0, CC-BY-SA-4.0	erlaubt (Namensnennung bzw. Weitergabe unter gleichen Bedingungen beachten, wenn die Lizenz es verlangt)
CC-BY-NC-4.0, CC-BY-NC-SA-4.0	nicht erlaubt
custom/personal-only (Standard)	nicht erlaubt; Ergebnisse bleiben auf Ihrem Computer
custom/test-use-only	nicht erlaubt; nur zum Testen, keine Veröffentlichung

- **Offene Universalstimme** (englisch: *Open universal voice*, russisch: *Открытый универсальный голос*) – eine englische Stimme für alle, die keine eigene Aufnahme haben. Nur mit dem gemeinfreien LJ-Speech-Datensatz trainiert (Sprecherin Linda Johnson, LibriVox); Lizenz **CC0-1.0** – für jede Nutzung frei, auch kommerziell; die Nennung des LJ-Speech-Datensatzes (Keith Ito) ist erwünscht.


Sie wird getrennt (nicht im Installationsprogramm enthalten) aus dem Stimmen-Repository geladen.

Die Bilder hier und in Kapitel 5 verwenden Demonstrationsstimmen. Stimmen, die Sie selbst trainieren, sind standardmäßig **nur für den persönlichen Gebrauch** (Umfang „**Nur privat**“): keine öffentliche Nutzung der Ausgabe, keine kommerziellen Projekte.

Das Badge ist eine Information, keine Rechtsberatung. Die Lizenz gilt nur für das Stimmenmodell.

8 Einstellungen

Öffnen Sie **Einstellungen** mit dem Zahnrad (oben rechts im Studio und in den anderen Fenstern).



Einstellungen (englische Oberfläche). (Screenshot der englischen Oberfläche)

Bedienelement	Was es tut
Sprache	Die Oberflächensprache: English, Deutsch, Русский. Sie ändert sich sofort in allen Fenstern.
Maximale Qualität (automatisch)	Wählt alle empfohlenen automatischen Optionen und lädt die nötigen Modelle (siehe unten).
Nach Updates suchen	Prüft, ob neuere verifizierte Versionen von Komponenten oder Modellen existieren, und installiert sie (mit Sicherheitsprüfung und automatischem Zurückrollen). Voxprint prüft außerdem einmal pro Woche unauffällig. Meldungen: „ Alles ist bereits aktuell. “, „ Starten Sie das Programm neu, um die Updates zu verwenden. “
Modellordner öffnen	Öffnet den Ordner mit den heruntergeladenen Modellen.

Bedienelement	Was es tut
Daten- und Protokollordner öffnen	Öffnet den Daten- und Protokollordner – schicken Sie das Protokoll dem Entwickler, wenn ein Fehler wiederkehrt.
Modelle und Stimmen – Kontrollkästchen Meine Stimmen einschließen	Ob Ihre Stimmenbibliothek zur Sicherung gehört (standardmäßig an).
Modelle und Stimmen sichern...	Kopiert Modelle (und Stimmen) in einen gewählten Ordner oder auf ein Laufwerk. Zeigt vorab Größe und freien Platz; fortsetzbar; identische Dateien werden übersprungen; jede Kopie wird geprüft. Fortschrittsbalken und eine Schaltfläche Abbrechen erscheinen.
Aus Sicherung wiederherstellen...	Stellt aus einem Ordner Voxprint-backup wieder her. Stimmen, die schon mit anderem Inhalt existieren, werden nie überschrieben.
Ordner mit vorhandenen Modellen	Modelle einer früheren Installation oder Sicherung: Vor jedem Download werden sie (gleiches Laufwerk) verknüpft oder nach Voxprint kopiert und per Prüfsumme kontrolliert. Ordner wählen... wählt den Ordner, Entfernen vergisst ihn.
Installation reparieren	Prüft Voxprints eigene Umgebung und behebt Schäden . Ihre Stimmen und Modelle bleiben erhalten.
Info	Version, die Idee, Funktionsweise, Open-Source-Komponenten mit ihren Lizenzen, ein Link zum GitHub-Repository und Hinweise zu Drittsoftware.
Schließen	Schließt den Dialog.

Bemerkt das Programm eine beschädigte Installation, bietet ein Banner die Reparatur an („**Die Voxprint-Installation muss repariert werden: ...**“). Hilft die Reparatur in der installierten Version nicht, starten Sie das Voxprint-Installationsprogramm erneut – Stimmen und Modelle bleiben erhalten.

Findet das Programm eine ältere Komponente in einer Umgebung, die ihm nicht gehört (zum Beispiel Ihr eigenes Python), fragt es zuerst: „**Neuere Komponente verfügbar**“ mit **Aktualisieren** oder **Nicht jetzt** ; Ihre Umgebung ändert es nie stillschweigend.

8.1 Maximale Qualität (automatisch)

Ab Werk ist alles, was automatisch laufen kann, **bereits gewählt** und mit einem Stern und dem Wort „**empfohlen**“ markiert: Wenn Sie nichts anfassen, arbeitet Voxprint mit maximaler Qualität. Die Schaltfläche **Maximale Qualität (automatisch)** in den Einstellungen wählt diese Optionen erneut (falls Sie welche abgeschaltet haben) und lädt die dafür nötigen Modelle mit Fortschrittsbalken. Die einzelnen Kontrollkästchen bleiben in ihren Fenstern.

- Textaufbereitung („Buch vertonen“): die sieben regelbasierten Schritte – Layout, Fußnotenmarken und Seitenzahlen, Anführungszeichen und Striche, Links, Kapitelüberschriften, Zahlen in Worten, Abkürzungen.
- KI-Korrektur von Tippfehlern (russische Bücher; einmaliger Download von etwa 365 MB).
- Trainingsfenster: „**Stimme nach dem Training prüfen (empfohlen)**“ und „**2 Varianten vergleichen**“ (beide brauchen das Spracherkennungsmodell, etwa 1,9 GB, einmal geladen).
- Immer aktiv, ohne Schalter: Ausrichtung des Textes auf das Audio mit Plausibilitätsprüfung, Audio-Qualitätsfilter, Erkennungsfilter des Nur-Audio-Modus.
- Nicht enthalten, weil es sie noch nicht gibt: Zeichensetzungsmodell, Betonungszeichen, Übersetzung, Sprecherrollen.



Die Trainingsvorgabe bleibt absichtlich bei „**Ausgewogen (empfohlen)**“: In unseren Tests ließ längeres Training mit höherer Lernrate die Stimme nuscheln, mehr ist dort also nicht besser. Stattdessen wird nach „**2 Varianten vergleichen**“ die bessere der beiden Varianten als „**empfohlen**“ markiert (zuerst das Urteil, dann weniger Erkennungsfehler, dann die kleinere Tonhöhenabweichung; ohne klaren Unterschied Variante A, die günstiger ist). Die Entscheidung bleibt bei Ihnen: Hören Sie immer hin.

9 Glossar

Adapter (LoRA)

Eine kleine Add-on-Datei (einige zehn MB), die dem großen Sprachmodell eine bestimmte Stimme „beibringt“. Technisch LoRA – Low-Rank Adaptation. Die Schaltfläche „ **Stimme erstellen (LoRA)** “ erzeugt ihn.

Universalmodell

Der zu einem vollständigen Modellordner von etwa 4 GB zusammengeführte Adapter. Er funktioniert in jeder App mit Qwen3-TTS.

Qwen3-TTS

Das offene Sprachsynthese-Modell, mit dem Voxprint spricht. Das Basismodell steht unter der Apache-2.0-Lizenz.

Datensatz

Das Trainingsmaterial, das Voxprint aus Ihrer Aufnahme schneidet: kurze Clips (3–12 s) mit ihren Texten, ein Referenzclip und ein Bericht.

Ausrichtung (Alignment)

Feststellen, in welcher Sekunde der Aufnahme jedes Wort des Textes gesprochen wird. Dadurch lässt sich an Pausen schneiden, nie mitten im Wort.

Clip / Fragment

Ein kurzes Stück der Aufnahme im Datensatz. Im Vertonungsfenster bedeutet „Fragment 3 von 8“ ein Stück des Buches.

Chunk

Ein Stück des Buchtextes von etwa einem Satz oder Satzteil, das dem Stimmmodell auf einmal übergeben wird. Die Oberfläche nennt es „Fragment“. Fertige Chunks werden gespeichert – dadurch ist die Vertonung fortsetzbar.

Batch (Stapel)

Mehrere Chunks, die das Stimmmodell zusammen in einem Aufruf erzeugt. Größere Batches sind viel schneller, brauchen aber mehr Videospeicher (bis zu 12 gleichzeitig).

RTF (Echtzeitfaktor)

Sekunden Rechenzeit pro Sekunde erzeugtem Audio. 0,31 bedeutet, dass eine Stunde Hörbuch etwa 19 Minuten dauert. Je niedriger, desto schneller.

Epoche / Durchlauf

Ein vollständiger Durchgang des Trainings durch Ihre gesamte Aufnahme (Oberfläche: „ **Durchläufe der Aufnahme (Epochen)** “). Die Stimmenliste zeigt, wie viele Epochen eine Stimme trainiert wurde.

Trainingsstufe (Preset)

Ein fertiger Satz Trainingszahlen: **Schnell** , **Ausgewogen (empfohlen)** , **Maximum** , **Manuell** .

Rang, Alpha, Lernrate, Gradientenakkumulation

Technische Trainingszahlen unter „ **Erweitert** “; siehe Abschnitt 6.3.

Vorschau (Preview)

Unter „ **Meine Stimmen** “: eine kurze Probe einer Stimme (Schaltfläche „ **Anhören** “). Im Trainingsfenster: die *schnelle Vorschau* – ein kurzes Probetraining mit einer Probe von etwa 10 s und automatischen Prüfungen; zu Ihren Stimmen wird nichts hinzugefügt.

**Erkennungsfehler (WER)**

Der Anteil der Wörter, die ein automatischer Zuhörer (Qwen3-ASR) beim Abschreiben der erzeugten Probe falsch versteht. Je niedriger, desto besser.

Tonhöhe, Halbtone

Wie hoch die Stimme ist. Ein Halbton ist der kleinste Schritt am Klavier. „Tonhöhe gegenüber Ihrer Aufnahme: +1,2 Halbtöne“ heißt: Die Stimme ist etwas höher als das Original.

Einverständnis

Die Erlaubnis des Stimminhabers, am Ende der Aufnahme gesprochen oder von Hand eingegeben und mit der Stimme gespeichert. Ein Vermerk, keine Rechtsberatung.

Umfang (Scope)

Was das Einverständnis erlaubt: „**Kommerziell**“, „**Öffentlich, nichtkommerziell**“ oder „**Nur privat**“.

Lizenz-Badge / Umfang-Badge

Farbige Kennzeichen auf der Stimmenkarte und im Vertonungsfenster. Grün: kommerzielle Nutzung erlaubt. Bernstein: eingeschränkt. Das Badge ist eine Information, keine Rechtsberatung.

Stimmtyp

Eine optionale Kennzeichnung der Stimme: männlich, weiblich, Kind oder andere. Wird mit der Stimme gespeichert.

Mini-Player

Der kleine Player im Vertonungsfenster, der den fertigen Teil des Buches abspielt, während der Rest noch entsteht.

Bitrate (kbit/s)

Wie viele Daten eine Sekunde Ton braucht. Höher bedeutet bessere Qualität und größere Dateien. Sprache braucht wenig: Opus mit 32 kbit/s reicht völlig.

Opus, MP3, AAC / M4B, FLAC, WAV

Audioformate. Opus: klein, offen, frei. MP3: läuft überall. AAC im M4B-Container: für Apple Books (patentbehaltet). FLAC und WAV: verlustfrei, große Dateien für Archiv und Bearbeitung.

Kapitelmarken

Lesezeichen innerhalb einer einzelnen Audiodatei, mit denen ein Player von Kapitel zu Kapitel springen kann.

Videospeicher (VRAM)

Der Speicher der Grafikkarte. Er begrenzt die Größe von Modell und Batch.

Fortsetzen (Resume)

Eine angehaltene Vertonung oder einen Download an der Stelle weiterführen, an der er stehen blieb.

Prüfsumme (SHA-256)

Ein Fingerabdruck einer Datei, der beweist, dass sie unbeschädigt heruntergeladen oder kopiert wurde.

Spiegel (ModelScope)

Ein alternativer Download-Server, den Voxprint nutzt, wenn Hugging Face langsam oder nicht erreichbar ist.

Reparieren (Repair)

Prüft die eigene Umgebung von Voxprint erneut und behebt, was defekt ist.

10 Fehlerbehebung und häufige Fragen

Welche Meldungen kann ich bekommen, und was tue ich?

Meldung	Was zu tun ist
Die Aufnahme ist zu kurz (unter 10 Sekunden). Es werden mindestens einige Minuten benötigt.	Nehmen Sie länger auf – 5–15 Minuten.
Die Audiodatei konnte nicht gelesen werden. Versuchen Sie ein anderes Format (WAV oder MP3).	Wandeln Sie die Aufnahme in WAV oder MP3 um.
Aufnahme und Text scheinen nicht zusammenzupassen: Der Text ist deutlich länger oder kürzer als die Aufnahme. Prüfen Sie, ob Sie die richtigen Dateien gewählt und den ganzen Text gelesen haben.	Prüfen Sie, ob Sie die richtige Audio- und Textdatei gewählt und den ganzen Text gelesen haben.
Die Aufnahme enthält lange Sprachabschnitte, die nicht im Text stehen (am Anfang oder am Ende). Schneiden Sie das Überflüssige ab oder wählen Sie einen anderen Text.	Schneiden Sie die überzählige Sprache am Anfang oder Ende der Aufnahme ab oder wählen Sie den richtigen Text.
Alle Fragmente der Aufnahme waren zu leise oder verzerrt. Prüfen Sie das Mikrofon und nehmen Sie erneut auf.	Prüfen Sie Mikrofon und Pegel; nehmen Sie an einem ruhigeren Ort neu auf.
Nicht genug Grafikspeicher (VRAM).	Schließen Sie andere Programme, die die Grafikkarte nutzen; Voxprint versucht es mit geringerer Last erneut („Nicht genug Grafikspeicher - neuer Versuch mit geringerer Last...“). Als letzter Ausweg: Auf dem Prozessor fortfahren (langsam) .
Das Modell {short} konnte nicht heruntergeladen werden. Prüfen Sie die Internetverbindung und versuchen Sie es erneut. Das Modell kann auch manuell heruntergeladen werden: {url}	Prüfen Sie Ihre Internetverbindung und starten Sie neu; der Download läuft an der gleichen Stelle weiter.
Die Sprach-Engine ist bei Fragment {n} fehlgeschlagen. Fertige Fragmente sind gespeichert – starten Sie erneut, um fortzusetzen.	Drücken Sie erneut Vertonung starten – fertige Fragmente bleiben erhalten.
Für dieses Format wird ffmpeg benötigt, es wurde aber nicht gefunden. Nutzen Sie „Reparieren“ in den Einstellungen oder wählen Sie WAV.	Einstellungen → Installation reparieren , oder wählen Sie WAV.
Nicht unterstütztes Buchformat. Verwenden Sie TXT, FB2 (oder FB2.ZIP) oder EPUB.	Wandeln Sie das Buch in TXT, FB2 oder EPUB um.
Die Buchdatei wirkt unsicher oder ist zu groß und wurde nicht geöffnet.	Die Datei wirkt beschädigt oder zu groß; versuchen Sie eine andere Kopie.
Es wird keine NVIDIA-Grafikkarte verwendet: Das Training läuft auf dem Prozessor und dauert viele Stunden. Für ein schnelles Ergebnis ist eine NVIDIA-Grafikkarte nötig.	Training ist ohne NVIDIA-Karte möglich, aber extrem langsam.



Meldung	Was zu tun ist
Der abschließende Trainingsfehler ist niedrig ($\{loss\} < \{threshold\}$): Die Stimme klingt womöglich verwaschen oder die Sprache endet nicht. Wenn es schlecht klingt, nehmen Sie mehr Text auf und wiederholen Sie es.	Die Stimme kann brabbeln. Wählen Sie Ausgewogen (empfohlen) , nehmen Sie mehr Text auf und hören Sie die schnelle Vorschau an.

Die Stimme klingt höher als meine. Eine leichte Tonhöhen-Drift nach oben (bei einer männlichen Stimme wurden etwa +2...+3 Halbtöne beobachtet) ist ein bekannter Effekt dieser Art von Training. Die automatische Prüfung warnt oberhalb von +4. Probieren Sie die schnelle Vorschau mit beiden Varianten und nehmen Sie die näherliegende.

Die Stimme brabbelt oder hört nicht auf. Zu viele Durchläufe oder zu hohe Lernrate. Wählen Sie „**Ausgewogen (empfohlen)**“ und erhöhen Sie die Lernrate nie von Hand.

Kann ich anhalten und später weitermachen? Vertonung: ja, immer (Abschnitt 5.5). Downloads und Sicherungen: ja. Training: Abbrechen ist möglich, ein voller Lauf beginnt aber von vorn; nutzen Sie vorher die schnelle Vorschau.

Darf ich meine Stimme für ein veröffentlichtes Hörbuch verwenden? Nur wenn der Einverständnis-Umfang es erlaubt („**Kommerziell**“ zum Verkaufen; „**Öffentlich, nichtkommerziell**“ zum kostenlosen Veröffentlichen). Ohne Einverständniserklärung trainierte Stimmen sind *nur privat*. Die Lizenz können Sie unter **Details..** ändern, wenn die Stimme Ihnen gehört.

Schickt Voxprint meine Aufnahmen irgendwohin? Nein. Ins Internet gehen nur der Download von Modellen, die Update-Prüfung und – wenn Sie das Repository öffnen – das Abrufen des Stimmenindex und der von Ihnen gewählten Stimmen. Keine Telemetrie, kein Konto.

Welche Sprachen werden unterstützt? Die Oberfläche: English, Deutsch, Русский. Die Textvorbereitung deckt Russisch und Englisch vollständig ab. Das Sprachmodell kann weitere Sprachen, sie sind aber nicht getestet.

Wo ist das Protokoll? Schaltfläche „**Daten- und Protokollordner öffnen**“ in den Einstellungen. Schicken Sie die Datei von dort, wenn ein Fehler wiederkehrt.

Ist die Option AAC / M4B sicher zu verwenden? Sie ist optional und standardmäßig aus gutem Grund ausgeschaltet: AAC ist patentbehaftet, und für die Einhaltung der Gesetze sind Sie verantwortlich (Abschnitt 5.4).

11 Lizenzen und Verantwortung

- **Der eigene Quellcode von Voxprint steht unter der Apache License 2.0** (Copyright 2026 Aleksandr Mitroshenkov; siehe die Dateien `LICENSE` und `NOTICE`).
- **Die Apache-Lizenz des Codes gilt nicht für Modelle und Stimmen.** Die Modelle, die Voxprint herunterlädt (Qwen3-TTS, Qwen3-ASR und die optionalen Textmodelle), behalten die Lizenzen ihrer Autoren. Jede Stimme hat ihre eigene Lizenz, als Badge angezeigt und in `voice.json` gespeichert.
- Komponenten von Drittanbietern samt Lizenzen sind unter „**Info**“ sowie in `THIRD_PARTY_NOTICES.md` und im Ordner `licenses` der Installation aufgeführt. Qt/PySide6 wird unter der LGPL-3.0 verwendet; das mitgelieferte ffmpeg ist ein eigenes Programm mit eigener Lizenz; der AAC-Codec ist patentbehaltet.
- **Verwenden Sie Stimmen verantwortungsvoll.** Eine Stimme ist ein personenbezogenes Datum und ein Persönlichkeitsrecht. Verwenden Sie eine Stimme nur mit ausdrücklicher Erlaubnis ihres Inhabers und im Rahmen ihrer Lizenz; keine Nachahmung von Personen, kein Betrug, keine irreführenden Inhalte; kennzeichnen Sie synthetische Sprache, wo dies vorgeschrieben ist. Für die rechtmäßige Verwendung der von Ihnen erzeugten Stimmen und Audios sind Sie verantwortlich.

Dieses Handbuch und die Lizenz-Badges sind Informationen, keine Rechtsberatung. Die Einverständniskarte hält fest, was eine sprechende Person gesagt hat; sie ersetzt nicht das Recht Ihres Landes.

Voxprint AI Audiobook Builder 0.1.0 (Beta). Handbuch vom 3. Oktober 2026.

Voxprint AI Audiobook Builder ist ein unabhängiges Projekt und steht in keiner Verbindung zu anderen Produkten oder Diensten mit ähnlichen Namen.